

۱- ارجاع به مقاله انتخابی جهت پیاده سازی

Sasirekha, K. and K. Thangavel. "Optimization of K-nearest neighbor using particle swarm optimization for face recognition." Neural Computing and Applications (2018): 1-10.

۲- انگیزه انتخاب موضوع و مقاله

در زمان کارشناسی و از ترم پنجم که طی یک مشارکت علمی در یک کار پژوهشی با مفاهیم هوش مصنوعی و خصوصاً یادگیری ماشین آشنا شدم؛ همواره بحث کار با مجموعه داده های تصویری و پژوهش روی آن و پیاده سازی تکنیک های مختلف (نظیر تسک های پیش پردازش و استخراج ویژگی تا کاهش ابعاد و کلاس بندی و...) جزو مباحث مورد علاقه بنده بوده و برای انجام یک پروژه دلخواه در بین اولویت های من قرار داشته است. (نمونه این انگیزه و توجه در انجام تمرینات طول ترم که به مجموعه داده های تصویری مربوط می شد قابل ملاحظه است) از این رو، بر آن شدم مقاله انتخابی برای پیاده سازی روی تصاویر باشد. از سویی دیگر، علاقه ام به الگوریتم های جست و جو و بهینه سازی مبتنی بر جمعیت (population-based) که معمولاً ناشی از زندگی جمعی در طبیعت است باعث شد تا حد امکان جست و جوی خود برای انتخاب مقاله به ترکیب این دو سوق دهم.

همچنین در زمان جست و جوی موضوع مقاله (همانطور که در ایمیل ارسالی نیز اشاره شده بود)، به مباحثی از image classification علاقمندتر شدم که در آن استخراج ویژگی از تصاویر بر اساس آنالیز بافت (texture) آنها صورت می گیرد. بین روش های موجود چندین مقاله در خصوص متد های Local Binary Pattern (LBP) و Gray Level Co-occurrence (GLCM) Matric مطالعه کرده و در نهایت به سمت مقاله های LBP علاقمندتر شدم و در نهایت با ترکیب کلید واژه های فوق به مقاله ای انتخابی خود رسیدم.

۳- تعریف مساله

از انتخاب پارامتر های مورد نیاز برای هر یک از مدل های هوش مصنوعی و همچنین انتخاب ویژگی (Feature Selection) از مجموعه کل ویژگی (به عبارتی subset selection) به عنوان یک زمینه تحقیقاتی همیشه باز و چالشی میتوان یاد کرد که روش های آماری و بهینه سازی متعددی برای جست و جو در فضای حالت معرفی و پیشنهاد شده است. هدف از انجام این پروژه بهینه سازی و حل مساله یافتن مقداری مناسب برای هایپر پارامتر K در الگوریتم K-NN با محوریت قرار دادن تشخیص چهره می باشد.

رویکرد پیشنهادی برای انتخاب هایپر پارامتر K استفاده از بهینه سازی ازدحام ذرات (Particle Swarm Optimization) با توجه به صحت خروجی مدل به عنوان هزینه می باشد. این روش بهینه سازی الهام از رفتار اجتماعی پرواز منظم پرندگان (bird flock) و مدرسه ماهی ها (fish school) بوده و یک الگوریتم تکاملی مبتنی بر جمعیت (population-based) محسوب می شود.

همچنین در این پژوهش سه روش بهینه سازی مبتنی بر جمعیت برای حل مساله انتخاب ویژگی با هدف بالا نگه داشتن accuracy مدل بررسی شده و برای هر کدام نیز نتیجه رویکرد پیشنهادی ارزیابی و گزارش گردیده است. روش های بهینه سازی شامل الگوریتم ژنتیک (Genetic Algorithm)، بهینه سازی ازدحام ذرات (Particle Swarm Optimization) و بهینه سازی کلونی مورچه ها (Ant Colony Optimization) می باشد.

۴- گام های پژوهش و پیشبرد رویکرد پیشنهادی

۴-۱- انتخاب مجموعه داده

مجموعه داده مورد پژوهش برای پیشبرد اهداف و استناد در مقاله شامل دو مجموعه داده می شود. اولین و مورد بحث ترین مجموعه داده که نتایج آن بیشتر مورد بررسی و خطاب قرار گرفته است، مجموعه داده جمع آوری شده توسط خود نویسندگان بوده که شامل تصاویر چهره های ۱۵۵ نفر و هر کدام در ۱۰ حالت مختلف می باشد. به غیر نمونه های آورده شده در مقاله، جزئیاتی از این مجموعه داده (نظیر مشابهت عوامل محیطی، پس زمینه ها و...) ذکر نشده است. مجموعه داده دوم نیز مجموعه داده ی عمومی ORL می باشد که حاوی تصاویر چهره های ۴۱ نفر و هر کدام در ۱۰ حالت مختلف می باشد.

۴-۲- استخراج ویژگی

برای استخراج ویژگی روی مجموعه داده ی تصاویر از اعمال Local Binary Pattern (LBP) و استفاده از بردار هیستوگرام حاصل از آن استفاده شده است. LBP یک عملگر روی تصویر می باشد که بافت تصویر را توصیف می کند. اساس کار آن سنجش پیکسل های همسایه ی هر پیکسل به ازای بزرگی و کوچکی آن می باشد.

۴-۳- انتخاب ویژگی

در این پژوهش از همه ی ویژگی های حاصل از بردار LBPH به خاطر تعداد بالا استفاده نشده است و تاکید بر آن بوده است که تعدادی از ویژگی ها برای تشخیص چهره استفاده شوند. در سه قسمت، سه روش بهینه سازی برای انتخاب ویژگی مطرح و مورد ارزیابی قرار گرفته است که در زیر به صورت خلاصه به بررسی الگوریتم ها پرداخته شده است. تابع سودمندی مد نظر گرفته شده برای ارزیابی هر یک، دقت مدل K-NN می باشد:

۱) الگوریتم ژنتیک (Genetic Algorithm): این الگوریتم بر اساس تکامل انسان در طی تولید مثل و ترکیب ژن ها از پدر و مادر معرفی شده است. روند کار آن بدان صورت است که تلاش میکند ژن (ویژگی) های مثبت و تاثیر گذار را از والدین حفظ و ژن (ویژگی) های نامطلوب را از مجموعه ویژگی های حاصل حذف نماید.

۲) بهینه سازی ازدحام ذرات (Particle Swarm Optimization): این بهینه سازی یک روش تکاملی و بر اساس نظر جمعی است. در این روش تعدادی ذره (عامل های جست و جو) در حال بررسی و جست و جوی فضای حالت (subset) به سمت یافتن بهترین ویژگی های ممکن برای حفظ به جهت بهینه کردن دقت مدل استفاده شده است. در این الگوریتم عامل های جست و جو با سرعت های متفاوتی به سمت جهات گوناگون فضای حالت در حال حرکت هستند. در هر مرحله، سمت حرکت هر عامل حاصل از ترکیب وزن دار بهترین جهتی که خود عامل تا کنون یافته و جهتی که در بین کل عامل ها پیدا شده است می باشد. سرعت عامل ها با تکرار های بالا کم شده و همگرایی به بهترین نتیجه رخ می دهد.

۳) بهینه سازی کلونی مورچه ها (Ant Colony Optimization): این روش بهینه سازی برای یافتن بهینه ترین مسیر در یک مسئله مسیر یابی مطرح شده است که اساس آن رفتار جمعی مورچه ها (عامل های جست و جو) در مسیر یابی بین لانه و یک قطعه غذا می باشد. مورچه ها هر مسیری را که برای طی کردن برای رسیدن به غذا انتخاب می کنند، از خود ماده را در زمین به جا میگذارند تا مورچه های بعدی نیز بتوانند به دنبال آن مسیر منتهی به غذا را بیابند. مورچه های بعدی نیز که هر کدام در حال جست و جو هستند با پیمایش هایی این ماده را در مسیر های مختلف منتهی به غذا جا میگذارند. زمانی که مورچه ای بخواهد به لانه برگردد مسیری را انتخاب می کند که بیشترین ماده جاگذاری شده را دارد. تکرار این کار باعث می شود مسیری که نزدیک ترین است دارای بیشترین ماده باشد.

در این پژوهش که هدف آن تصمیم گیری بین ویژگی ها برای Selection می باشد، هر یک از مسیر ها برای عامل های هوشمند به منزله سودمندی سوپیج کردن بین ویژگی ها در نظر گرفته شده است.

۴-۴- انتخاب K و معیار distance در K-NN برای مرحله انتخاب ویژگی

برای Actual Features چندین معیار فاصله به ازای K های مختلف بررسی و گزارش شده است و هدف از انجام آن انتخاب معیار distance مناسب و K ایده آل برای استفاده در سنجش و ارزیابی تابع سودمندی برای قسمت انتخاب ویژگی می باشد. نتیجه حاصل بدین گونه بوده است معیار cosine عملکرد خوبی داشته که لذا مورد استفاده قرار گرفته است. همچنین با مقایسه جدول های ۹ و ۷ می توان متوجه شد که K برابر با ۳ فرض شده است.

۵-۴- بهینه سازی ابر پارامتر K در مدل پیش‌بینی K-NN

در این مقاله، برای یافتن مقدار مناسب برای K از روش بهینه سازی ازدحام ذرات (PSO) استفاده شده است. با عنایت به توضیحات قسمت قبل در خصوص PSO، تعدادی عامل جست و جو بین K های مختلف در حال جست و جو هستند که اساس تابع سودمندی بنا بر ارزیابی accuracy مدل در نظر گرفته شده است. پس از همگرایی، بهترین K حاصل که بیشترین میزان موفقیت در ارزیابی را داشته است به عنوان K نهایی انتخاب و مورد استفاده قرار می گیرد.

۵- پیاده سازی مجدد، چالش ها و نتایج

توجه: نمودار های حاصل از مقایسه ی بخش های پیاده سازی در بخش ۶ و جدا از توضیحات این بخش آورده شده است.

۱-۵- مجموعه داده

از بین دو مجموعه داده، تاکید بنده بر پیاده سازی مجدد بر اساس هر دو بود. با توجه به اینکه مجموعه داده اول عمومی نبوده و نویسندگان مقاله نیز به درخواست بنده برای به اشتراک گذاری آن پاسخی ندادند، پیاده سازی و عملیات مجدد صرفا با استفاده از مجموعه داده ی دومی (ORL) صورت گرفته است. دیتاست را از سایت [Kaggle](https://www.kaggle.com/datasets/orl-face) دریافت کرده و شروع به پیاده سازی کردم.

۲-۵- بارگیری مجموعه داده و استخراج ویژگی ها: فایل LBP-Feature Extraction

هدف از کد های نوشته شده در این فایل بارگیری مجموعه تصاویر، استخراج ویژگی، تفکیک به مجموعه داده های آموزش و آزمون و ذخیره بردار ویژگی های حاصل می باشد. ابتدا تصاویر در قالب آرایه های numpy لود شده اند. سپس بردار ویژگی آنها که حاصل از LBP و هیستوگرام آن می باشد محاسبه شده است.

برای LBP ما نیاز به پارامتر های (P,R) که نشان دهنده تعداد پیکسل های همسایه و شعاع همسایگی می باشد داریم که در متن مقاله هیچ اشاره ای به آن نشده است. همچنین نیاز به تعداد bins های مفروض برای هیستوگرام داریم که ان نیز در مقاله درج نشده است. این پارامتر ها از جایی که بسیار مهم بوده و در تولید بردار ویژگی و در ادامه مسیر موثر هستند بایستی مقدار مناسبی برای آنها در نظر گرفت. با استناد به مقالات موجود در سطح اینترنت و [این مقاله](#) که ضمیمه نیز شده است؛ تعداد همسایگی برابر با ۸ و شعاع همسایگی برابر با ۱ در نظر گرفته شده و هیستوگرام تولید شده نیز با ۲۵۶ bins تولید شده است. لذا طول بردار ویژگی برابر با ۲۵۶ خواهد بود. (با توجه به جدول شماره ویژگی های انتخابی در مقاله، می توان انتظار داشت طول این بردار احتمالا بزرگتر از طول بردار مورد پژوهش نویسندگان بوده است)

پس از تولید بردار ویژگی ها، مجموعه داده به دو قسمت آموزش و آزمون با نسبت ۲۰ به ۸۰ تقسیم شده و در قالب آرایه های numpy ذخیره شده اند که در پوشه ضمیمه شده قابل دسترس است. ضمناً تقسیم مجموعه داده بصورت balanced از همه کلاس ها صورت گرفته است.

صحت مدل پیش بینی K-NN برای این مجموعه داده با معیار cosine و $k=3$ برابر با ۸۵.۳۶٪ حاصل شده است که تقریباً ۷ درصد پایین تر از نتیجه گزارش شده در مقاله می باشد که می توان دلیل این تفاوت را فرض در پارامترهای فوق الذکر دانست که این روند در ادامه بخش های نیز ملاحظه خواهد شد.

۱-۳-۵- انتخاب ویژگی با الگوریتم ژنتیک (GA): فایل LBP-GA

هدف از کد های نوشته شده در این فایل انتخاب ویژگی با استفاده از الگوریتم ژنتیک می باشد که در انتها اندیس ویژگی های انتخاب شده بصورت آرایه ذخیره می شود.

ابتدا بردارهای ویژگی که در قسمت قبل تولید و ذخیره شده بود در این قسمت بارگیری می شوند. سپس با استفاده از کتابخانه آماده ی مربوطه (sklearn_genetic)، فرآیند انتخاب ویژگی صورت گرفته است. تعداد ویژگی های انتخاب شده برابر با ۸۲ و صحت مدل پیش بینی K-NN نیز با معیار cosine و $k=3$ برابر با ۸۶.۵۸٪ حاصل شده است که ۸ درصد پایین تر از نتیجه گزارش شده در مقاله می باشد اما با این وجود، رابطه آن نسبت به Actual Features همین پیاده سازی صادق با گزارش مقاله بوده و ضمن انتخاب تعداد ویژگی کمتر دقت آن نیز تقریباً ۱.۵٪ افزایش پیدا کرده است. با توجه به توضیحات قسمت ۵-۲ که احتمال می رود تعداد ویژگی ابتدایی نسبت به مقاله بیشتر در نظر گرفته شده است لذا پارامتر جمعیت مورد بررسی ۳۰ و پارامتر جهش نسل ۲۰ در نظر گرفته شده است. (همچنین پارامترهای احتمالاتی در جدول اشتباه درج شده بود چرا که مجموع احتمال بیشتر از یک می شد. لذا به جای این مورد از مقدار پیش فرض کتابخانه استفاده شده است)

۲-۳-۵- انتخاب ویژگی با بهینه سازی ازدحام ذرات (PSO): فایل LBP-PSO

هدف از کد های نوشته شده در این فایل انتخاب ویژگی با استفاده از بهینه سازی ازدحام ذرات می باشد که در انتها اندیس ویژگی های انتخاب شده بصورت آرایه ذخیره می شود.

ابتدا بردارهای ویژگی که در قسمت استخراج ویژگی تولید و ذخیره شده بود در این قسمت بارگیری می شوند. سپس با استفاده از کتابخانه آماده ی مربوطه (PySwarms)، فرآیند انتخاب ویژگی صورت گرفته است. تعداد ویژگی های انتخاب شده برابر با ۱۳۷ و صحت مدل پیش بینی K-NN نیز با معیار cosine و $k=3$ برابر با ۹۰.۲۴٪ حاصل شده است که تقریباً ۵ درصد پایین تر از نتیجه گزارش شده در مقاله می باشد اما با این وجود، رابطه آن نسبت به Actual Features همین پیاده سازی صادق با گزارش

مقاله بوده و ضمن انتخاب تعداد ویژگی کمتر دقت آن نیز تقریباً ۵٪ افزایش پیدا کرده است. همچنین نتیجه این انتخاب ویژگی نیز نسبت به خروجی GA صادق با گزارش مقاله بوده و آن عملکرد بهتری داشته است. (تقریباً ۳.۵ درصد)

در مقاله به معیار سنجش فاصله بین ذرات و تعداد ذرات همسایه جهت محاسبه best global اشاره نشده است لذا از این رو معیار فاصله اقلیدوسی ($p=2$) و همسایگی کل ذره ($k=20$) در نظر گرفته شده است.

۳-۵- انتخاب ویژگی با بهینه سازی کلونی مورچه ها (ACO): فایل LBP-ACO

هدف از کد های نوشته شده در این فایل انتخاب ویژگی با استفاده از روش بهینه سازی کلونی مورچه ها می باشد که در انتها اندیس ویژگی های انتخاب شده بصورت آرایه ذخیره می شود.

ابتدا بردار های ویژگی که در قسمت استخراج ویژگی تولید و ذخیره شده بود در این قسمت بارگیری می شوند. سپس با استفاده از تابع توسعه پیدا شده از این [Repository](#)، فرآیند انتخاب ویژگی صورت گرفته است. توضیحات ذکر شده برای استفاده از این الگوریتم بهینه سازی و جزئیات پیاده سازی آن برای هدف انتخاب ویژگی چندان کامل ارائه نشده و صرفاً به تکرار رابطه ریاضیاتی خود بهینه سازی بسنده شده و شرح خوب و مفیدی از نگاهش این روش به مسئله موجود (انتخاب ویژگی) برای فاز پیاده سازی درج نشده است. مورد بعدی در خصوص این قسمت از مقاله، عدم ذکر پارامتر تعداد تکرار (iteration) برای عامل های جست و جوی الگوریتم می باشد که میتواند نتایج را دچار چالش های متفاوت کند. (که به علت زمان پردازی بالا امکان grid search نیز چندان میسر نبود)

با توجه به توضیحات قسمت ۵-۲ که احتمال می رود تعداد ویژگی ابتدایی نسبت به مقاله بیشتر در نظر گرفته شده است لذا پارامتر تعداد ant برابر با ۳۰ فرض شده است.

با وجود توضیحات فوق، پس از اجرای الگوریتم تعداد ویژگی های انتخاب شده برابر با ۲۴ و صحت مدل پیش بینی K-NN نیز با معیار cosine و $k=3$ برابر با ۸۷.۸۰٪ حاصل شده است که تقریباً ۷ درصد پایین تر از نتیجه گزارش شده در مقاله می باشد اما با این وجود، رابطه آن نسبت به Actual Features همین پیاده سازی صادق با گزارش مقاله بوده و ضمن انتخاب تعداد ویژگی کمتر دقت آن نیز تقریباً ۲٪ افزایش پیدا کرده است. همچنین نتیجه این انتخاب ویژگی نیز نسبت به خروجی GA صادق با گزارش مقاله بوده و از آن عملکرد اندکی بهتری داشته است (تقریباً ۲.۵ درصد).

همچنین رابطه نتیجه این انتخاب ویژگی نیز نسبت به خروجی PSO صادق با گزارش مقاله بوده و از آن عملکرد اندکی ضعیف تر داشته است. (تقریباً ۱ درصد)

۴-۵- بهینه سازی پارامتر k در K-NN با PSO: فایل PSO-KNN

هدف از کد های نوشته شده در این فایل جست و جو و یافتن K بهینه با استفاده از روش بهینه سازی PSO برای مدل K-NN به ازای ویژگی های انتخاب شده در قسمت های قبل می باشد. برای این بخش نیز از کتابخانه آماده ی مربوطه (PySwarms) استفاده شده است.

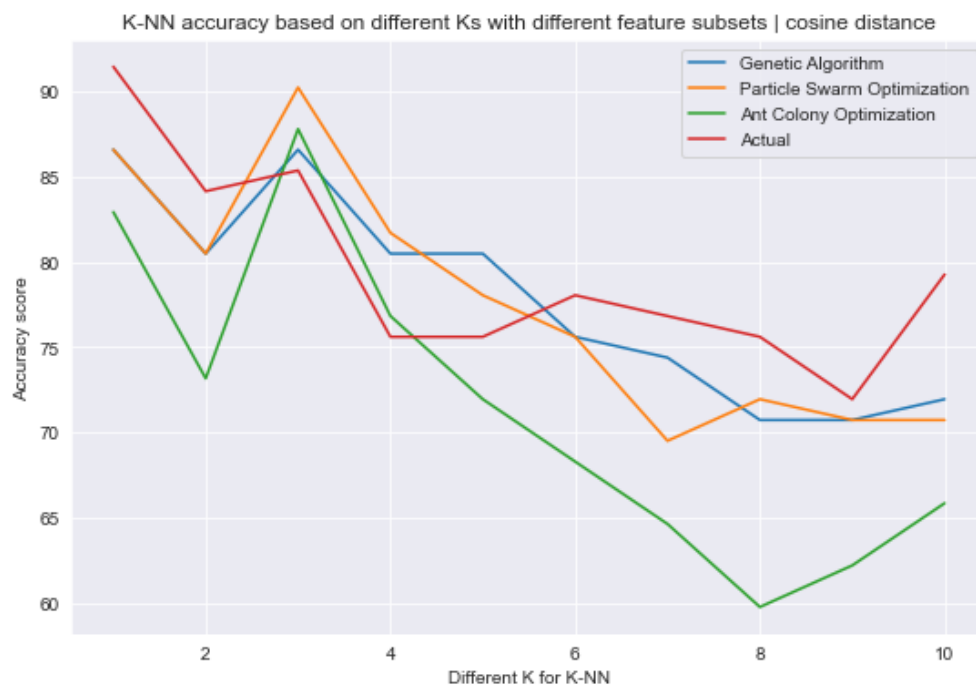




اولین مورد بحث در خصوص این قسمت از مقاله این است که بر خلاف قسمت انتخاب ویژگی که در یک جدول پارامتر های مورد نیاز ذکر شده بود، در این قسمت به هیچ کدام از پارامتر های PSO اشاره نشده است. دومین نکته اینکه هیچ جدول، نمودار یا توضیحی در خصوص نتایج عددی خود K درج نشده است و صرفاً به accuracy اکتفا شده است که این باعث ایجاد یک سوال می شود: K انتخابی در زمان انتخاب ویژگی در هر یک از الگوریتم ها چه عددی بوده و K بهینه که حاصل شده است چه عددی می باشد؟ (ما صرفاً بر اساس حدس و مقایسه جداول $K=3$ را در زمان انتخاب ویژگی در نظر گرفته و پیاده سازی را پیش بردیم که این ممکن است باعث شود نتیجه حاصل شده مطابق با رابطه مقاله نشود)

پس از اجرای این قسمت از مقاله نتایج آن نسبت به قسمت های قبل بصورت زیر حاصل شد:

Row No.	KNN		PSO-KNN	
	K	accuracy	K	accuracy
Actual Features	3	85.36	1	91.46
GA Features	3	86.58	1	86.58
PSO Features	3	90.24	3	90.24
ACO Features	3	87.80	3	87.80

در بین ویژگی های Actual بصورت واضح قابل مشاهده است که با تغییر K و یافتن مقدار بهینه آن، صحت پیش بینی مدل افزایش چشمگیر تقریباً ۶ درصدی یافته است. این مورد برای ویژگی های GA در خصوص K بوده و مقدار آن از ۳ به ۱ تغییر پیدا کرده است اما صحت پیش بینی تغییری نکرده است. (در نمودار قسمت بعد ملاحظه می شود به ازای دو عدد ۳ و ۱ صحت پیش بینی برای این دسته از ویژگی ها دقیقاً باهم برابر است و بهینه ساز PSO به عدد ۱ رسیده است) همچنین برای دو دسته ویژگی PSO و ACO هیچ تغییری در K و accuracy رخ نداده است. دلیل این امر را میتوان اینگونه استدلال نمود که در زمان انتخاب ویژگی ها، این الگوریتم های بهینه سازی ویژگی ها را طوری کنار هم چیده اند که با ۳ همسایه بتوانند نتیجه مطلوب را از تابع سودمندی (fitness) کسب نمایند لذا نتیجه بهینه ساز PSO تفاوتی با فرض ما ($k=3$) در زمان انتخاب ویژگی نداشته است.

۶- نمودار های مقایسه بخش های مختلف پیاده سازی: فایل report-generator



همانطور که از تراکم و فشردگی صعودی به ازای $K=3$ نمودار بالا مشخص است، نشان میدهد فرض ما در زمان انتخاب ویژگی در PSO-KNN نهایی موثر بوده است.

۷- تعمیم روش بهینه سازی PSO برای انتخاب بردار های ویژه در PCA برای تشخیص چهره: فایل PCA-PSO

در طول ترم و تمرینات ملاحظه شد روش PCA با استناد به واریانس ابعاد داده ها (پیکسل ها در تصاویر) و محاسبه بردار ویژه ها میتواند علاوه بر حذف نویز باعث کاهش ابعاد از طرق feature extraction شود. حال همانطور که در تمرین شماره ۶ از تکالیف دوره سوم مشاهده شد، بردار های ویژه متوالی هم گاه جزئیات کمتری را با خود نسبت به بردار های ویژه همسایه برای مرحله inverse حمل می کنند. (منظور بنده از جزئیات کمتر نسبت به برداری های ویژه در یک توالی می باشد)

از این رو، من انگیزه پیدا کردم که از PSO برای انتخاب برخی از بردار های ویژه در تبدیل PCA که ممکن است متوالی هم نباشند استفاده نمایم و نتیجه تشخیص چهره روی دیتاست ORL را با همان 3-NN و متریک فاصله cosine با بردار های ویژه انتخاب شده توسط PSO گزارش دهم. به جهت شباهت با اساس ویژگی های Actual حاصل از LBP که طول بردار ویژگی ۲۵۶ بود، تعداد کامپوننت پایه را ۲۵۶ کامپوننت اول در نظر گرفته ام که بیش از ۹۹ درصد واریانس داده ها را نیز پوشش میدهد.

در صورتی که صرفا از PCA محض با تعداد کامپوننت ۲۵۶ برای استخراج ویژگی از اصل تصاویر چهره برای تشخیص استفاده نمایم صحت مدل به ۹۲.۲۳٪ می رسد که نسبت به این سری از پیاده سازی ها و در سناریو های این مقاله، بالاترین عدد بدست آمده می باشد.


حال اگر PSO را برای جست و جو بین کامپوننت های PCA با در نظر داشتن افزایش accuracy اعمال کنیم؛ تعداد کامپوننت های انتخابی برابر با ۱۳۵ خواهد بود که با خصوصیات زیر حاصل می شود:

(۱) این تعداد تقریباً نصف تعداد کل ویژگی های ابتدایی می باشد (نزدیک به LBP-PSO)، لذا کاهش خوبی به جهت عددی بین ویژگی ها مشاهده می شود.

(۲) با وجود کاهش تقریباً ۵۰٪ تعداد کامپوننت ها، Accuracy معادل با این کامپوننت های انتخابی برابر با ۹۷.۰۸٪ حاصل شده است که بیشترین صحت بدست آمده در کل این پیاده سازی ها و حتی بالاتر از PCA محض می باشد که ۹۲.۲۳٪ بود. همچنین این دقت با اختلاف تقریبی فقط ۱٪ نزدیک به بالاترین عدد گزارش شده در کل مقاله برای مجموعه داده ORL می باشد.

(۳) نرخ explained variance کامپوننت های انتخابی توسط PSO معادل با ۸۰.۹۷٪ می باشد. این مورد نشان میدهد که افزایش accuracy ضمن کاهش پوشش واریانس اصل داده ها اتفاق افتاده است.

۴) همانطور که در نمودار زیر مشخص است به ازای هیچ تعداد کامپوننت PCA به صورت استفاده متوالی (اساس انتخاب PCA) نمیتوان به این دقت رسید.



این آزمایش که تعمیم رویه مقاله‌ی انتخابی بود نشان داد عملکرد PCA به عنوان feature extractor را می توان با تعمیم روش پیشنهادی PSO برای فاز انتخاب ویژگی با انتخاب تعداد محدود و غیرپشت سرهم تعدادی از کامپوننت ها بهبود بخشیده و در تسک تشخیص چهره با ویژگی های حاصل از PCA به دقت بالاتری حتی بیشتر از LBP یا PCA محض دست یافت. ضمناً اندیس کامپوننت های انتخاب شده در قالب فایل آرایه numpy ذخیره شده است.